

01 : Architecture du Transformer

Introduction à l'IA moderne

Modèle d'attention pure

Révolution du traitement naturel

Sommaire

- Vue d'ensemble du modèle
- Embeddings et position
- Fonctionnement de l'encodeur
- Fonctionnement du décodeur
- Génération des sorties

Vue d'ensemble

- Structure Encodeur et Décodeur
- Empilement de N couches
- Maniement de l'attention
- Connexions résiduelles systématiques

Embeddings et Encodage Positionnel

- Vectorisation des mots d'entrée
- Addition de l'encodage positionnel
- Maintien de l'ordre temporel
- Injection dans le réseau

L'Encodeur (Encoder Stack)

- Attention multi-têtes autonome
- Réseau Feed Forward
- Blocs Add and Norm
- Représentation contextuelle riche

Le Décodeur (Decoder Stack)

- Attention masquée du futur
- Attention croisée Encodeur Décodeur
- Réseau Feed Forward
- Prédiction séquentielle guidée

Génération de la Sortie

- Projection linéaire finale
- Fonction Softmax normalisatrice
- Distribution des probabilités
- Sélection du mot suivant

Conclusion

- Révolution de l'attention pure
- Parallélisation massive de calcul
- Socle des modèles LLM
- Perspectives et ouvertures