

01 : Architecture du Transformer

Introduction au modèle Transformer
Architecture Sequence-to-Sequence
Mécanisme d'attention pure
Révolution majeure en IA

Sommaire du cours

- Vue d'ensemble Encoder-Decoder
- Embeddings et Encodage Positionnel
- Le bloc Encodeur
- Le bloc Décodeur
- Génération des sorties

Entrées et Encodage Positionnel

- Plongement vectoriel des mots
- Représentation sous forme numérique
- Ajout du vecteur positionnel
- Conservation de l'ordre séquentiel

Le bloc Encodeur (Nx)

- Empilement de Nx couches
- Attention Multi-Têtes autonome
- Connexions résiduelles et normalisation
- Réseau Feed Forward connecté

Le bloc Décodeur (Nx)

- Empilement de Nx couches
- Attention Multi-Têtes masquée
- Attention croisée avec encodeur
- Masquage des mots futurs

Génération et Probabilités

- Couche linéaire de projection
- Fonction Softmax d'activation
- Probabilités sur le vocabulaire
- Prédiction du mot suivant

Conclusion et Synthèse

- Parallélisation optimale des calculs
- Capture des dépendances longues
- Fondation des LLM modernes
- Fin du cours 01