

TRANSF : L'Architecture Transformer

Introduction à l'IA
Architecture Sequence-to-Sequence
Révolution de l'Attention

Sommaire du cours

- Embeddings et Positionnement
- Structure de l'Encodeur
- Structure du Décodeur
- Couche de Sortie

1. Embeddings et Positional Encoding

- Vectorisation des données d'entrée
- Ajout d'information positionnelle
- Traitement parallèle des séquences

2. Le Bloc Encodeur (Nx)

- Attention multi-têtes auto-attentive
- Réseau Feed Forward intermédiaire
- Connexions résiduelles Add-Norm
- Empilement de N blocs

3. Le Bloc Décodeur (Nx)

- Attention masquée auto-régressive
- Attention croisée Encodeur-Décodeur
- Feed Forward et normalisation
- Empilement de N blocs

4. Projection et Softmax Final

- Projection linéaire du vecteur
- Calcul des probabilités Softmax
- Prédiction mot par mot

Conclusion

- Abandon de la récurrence
- Parallélisme d'entraînement massif
- Socle des LLM modernes