

# Transformer : Architecture de Référence

Modèle séquence-à-séquence révolutionnaire

Mécanisme d'attention sans récurrence

Fondation des LLM modernes

# Sommaire du Cours

- Embeddings et encodage positionnel
- Fonctionnement du bloc encodeur
- Architecture du bloc décodeur
- Génération des sorties finales

# Input & Positional Encoding

- Vectorisation initiale des mots
- Ajout de l'information spatiale
- Conservation de l'ordre séquentiel
- Transmission aux blocs supérieurs

## L'Encodeur : Attention & FFN

- Empilement de N blocs
- Multi-Head Attention globale
- Réseau Feed Forward fully-connected
- Connexions résiduelles Add & Norm

## Le Décodeur : Attention Masquée

- Entrées décalées à droite
- Masked Attention auto-régressive
- Cross-Attention avec l'encodeur
- Normalisation et liaisons résiduelles

# Génération et Probabilités

- Projection par couche linéaire
- Normalisation Softmax des scores
- Distribution sur le vocabulaire
- Sélection du prochain token

## Conclusion et Impact

- Parallélisation optimale de l'entraînement
- Dépassement des modèles RNN
- Standard de l'IA moderne