

Transformers : Architecture

- Introduction aux Transformers
- Révolution du NLP
- Architecture Encoder-Decoder

Sommaire

- Entrées et encodage positionnel
- Fonctionnement de l'encodeur
- Fonctionnement du décodeur
- Génération des probabilités

1. Traitement des Entrées

- Vectorisation par Input Embedding
- Inclusion du Positional Encoding
- Maintien de l'ordre temporel

2. L'Encodeur (Nx)

- Empilement de N blocs
- Attention multi-têtes autonome
- Réseaux Feed-Forward
- Connexions résiduelles Add-Norm

3. Le Décodeur (Nx)

- Attention multi-têtes masquée
- Attention croisée Encodeur-Décodeur
- Génération autorégressive des données

4. Génération des Sorties

- Couche linéaire de projection
- Normalisation par Softmax
- Calcul des probabilités finales

Conclusion

- Parallélisation efficace des calculs
- Gestion des dépendances longues
- Fondation des LLMs actuels